Otimização usando Programação em Lógica com Restrições

Gestão de Servidores Cloud

Duarte Duarte - ei11101, Hugo Freixo - ei11086 FEUP-PLOG, Turma 3MIEIC1, Grupo 45

Faculdade de Engenharia da Universidade do Porto Rua Roberto Frias, sn, 4200-465 Porto, Portugal

Resumo O objetivo do trabalho é otimizar servidores *cloud*, para a realização deste foram utilizadas restrições na linguagem Prolog. Conclui-se que os módulos de PLR de Prolog não são adequados quando a quantidade de informação a processar é elevada e que uma fraca especificação dos requisitos do problema leva a um trabalho atribulado sem conclusões pertinentes.

1 Introdução

Este trabalho tem como objetivo otimizar a gestão de um servidor *Cloud* através da linguagem Prolog. Pretende-se então simular pedidos a um servidor principal de distribuição (SPD), este apenas pode processar um pedido de cada vez, se for efetuado mais algum pedido enquanto outro está a ser processado no SPD, o pedido fica pendente numa fila de espera. O tamanho da fila é variável mas um novo slot tem um custo extra.

Todos os dados referentes à configuração base dos servidores, tempos de execução de tarefas, preços de hardware e requisitos dos diferentes tipos de pedidos podem ser alterados através de um ficheiro de texto.

O grupo achou o enunciado mal formulado e longe de uma situação real, por isso o problema foi relaxado de modo a facilitar a implementação dos detalhes complexos do problema e para obter uma solução, embora na mesma para valores baixos de pedidos, em tempo útil.

Este relatório é constituido por vários pontos. Começa por explicar o problema proposto ao grupo, depois aborda os ficheiros de dados utilizados para o *input* dos valores das variáveis do problema. Seguidamente são aborados os tópicos acerca das variáveis de decisão e restrições utilizadas na resolução deste trabalho, será descrita a função de avaliação, a estratégia de pesquisa e a visualização da solução. Este relatório finaliza com os resultados obtidos e com a conclusão e prespectivas de desenvolvimento.

2 Descrição do Problema

Para além do SPD referido no tópico acima, existem mais três tipos de servidores: servidor de autenticação, servidor de armazenamento e servidor de

execução de scripts. Estes servidores vão dar reposta a outros pedidos dependendo das suas exigências. Também existem vários tipos de pedidos e estes possuem um valor de espaço de disco, RAM e CPU que necessitam para serem processados. Estes valores são lhes cedidos pelos servidores e é escolhido o servidor mais apropriado para o tipo de pedido, por exemplo: se queremos guardar um ficheiro então utiliza-se uma máquina que tem muito espaço em disco; se queremos executar um programa então utiliza-se uma maquina que tem um nível de CPU elevado.

Processo seguido:

- Gerar uma lista ordenada aleatoriamente com os tipos de pedidos, respeitando as percentagens de cada tipo e número de pedidos especificados nos dados de entrada;
- Gerar múltiplas listas de tasks, com tempos de início e fim indefinidos, mas com duração, recurso a gastar e máquina em que corre definido;
- Gerar múltiplas listas de machines com os recursos apropriados (para um total de 9 máquinas (3 cada tipo x 3 cada recurso));
- Definir domínios às variáveis;
- Aplicar restrições;
- Pesquisar pela solução, obtendo a lista de tempos de início e fim de cada pedido;
- Ordenar e selecionar os tempos de início das tarefas;
- Usar o tempo de início das tarefas para calcular o número de "slots" a ser usados;
- Pegar em todos os dados calculados e calcular custo total e apresentar estatísticas e resultados.

3 Ficheiros de Dados

Os ficheiros de dados contêm os dados referentes à configuração base dos servidores (espaço, RAM e CPU dos servidores de autenticação, armazenamento e execução de *scripts*), os tempos de execução de tarefas e decisões de encaminhamento, o preço dos "slots" na fila de pedidos, requisitos dos vários tipos de pedidos, o número de pedidos a simular e a sua distribuição, em percentagem, e o orçamento disponível.

Estes ficheiros de texto são código válido de Prolog, constituídos pela declaração de fatos simples, por exemplo, $spd_slot_price(50)$..

A escalibilidade da solução pode ser verificada apenas alterando o número de pedidos (requests(X).). Foi testada um número de pedidos de 100, 1000 e 2500.

4 Variáveis de Decisão

Cada pedido real corresponde a 3 task/5 distintas, cada uma correspondendo a um tipo de recurso: RAM, CPU ou espaço. Da mesma forma, cada máquina real corresponde a 3 machine/2. As tasks são executadas na máquina respectiva,

tendo em conta o recurso que usam e o seu tipo (autenticação, armazenamento ou *script*). As máquina conseguem executar tarefas paralelamente desde que tenham recursos para tal, caso contrário, a tarefa é adiada.

Como variáveis de decisão temos o tempo de início e fim das tarefas, que tenta ser minimizado. O seu domínio é entre o tempo que demora a processar um pedido no SPD (no exemplo de configuração em anexo é 100 milisegundos) e o número de milisegundos num dia.

5 Restrições

A nível de restrições são usados 3 cumulatives/3 (um para tipo de recurso) de forma a associar as tarefas às máquinas. Como opção, é usado bound(upper) porque os tempos não têm um limite superior bem definido (embora seja objetivo a minimização deles).

6 Função de Avaliação

Depois de calculado os tempos de execução das tarefas ótimos, é calculado o número de slots no SPD necessários (sem recurso a PLR), ver predicado *calculate_cost_queues/4*.

7 Estratégia de Pesquisa

A estratégia de etiquetagem é a mais simples possível, apenas com recurso à chamada labeling([], StartTimes + End).. Não foi possível forçar a minimização dos tempos de terminação, com recurso a minimize/2 porque não era possível obter soluções em tempo útil.

8 Visualização da Solução

No fim do processamento dos dados de entrada é imprimido para o ecrã um conjunto de dados, tanto estatísticos como de resultados, sobre o problema.

Começa-se por mostrar estatísticas referentes ao módulo de PLR, fd-statistics/0, e de seguida estatísticas sobre o tempo de processamento do Prolog e memória usada, statistics/0. Quanto aos resultados, é mencionado o número de pedidos de cada tipo, o número de "slots" comprados para o SPD e SSD, o número de servidores comprados de cada tipo, o dinheiro que foi gasto no dimensionamento do sistema e o lucro ou prejuízo relativamento ao orçamento disponível inicialmente.

Exemplo de output:

Entailments: 4

| ?- init. ==== FD Statistics ===== Resumptions: 27752 Prunings: 6365252 Backtracks: 0

Constraints created: 4

====== Statistics ======

memory (total) 453050272 bytes

-- snip ---

54.063 sec. runtime

-- snip ---

====== Results ======

Number of Authentication Requests: 1250

Number of Storage Requests: 3000

Number of Script Execution Requests: 750

Number of SPD slots bought: 2240 Number of SSD slots bought: 0 Number of Authentication Servers: 1

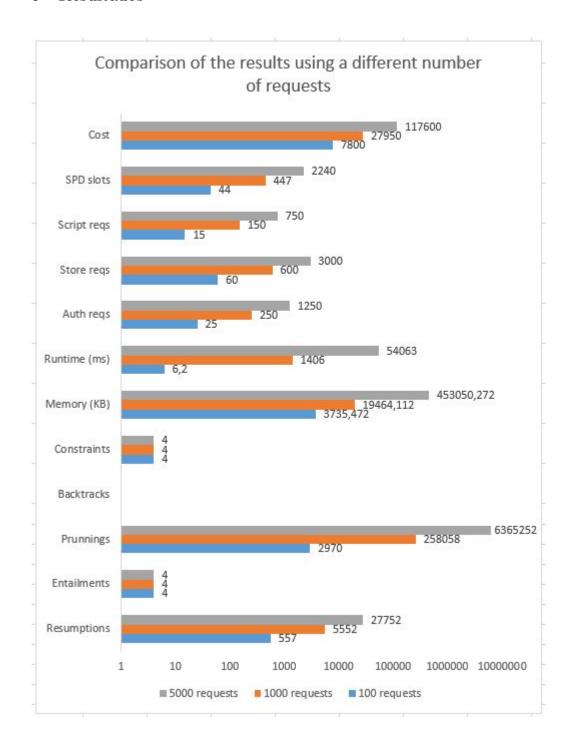
Number of Storage Servers: 1

Number of Script Execution Servers: 1

Available budget: 150000E

Total cost: 117600E Profit/Loss: +32400E

9 Resultados



No gráfico em cima são comparados as diferentes estatísticas e resultados para três diferentes numéro de pedidos: 100, 1000 e 5000. O número de pedidos de teste é relativamente baixo em relação a um sistema de realidade ou ao que era sugerido no enunciado do problema (cem milhões de pedidos) porque aumentando o número de pedidos aumenta exponencialmente (e de forma bastante acentuada) a RAM e tempo necessário à resolução do problema. Nota-se que para apenas 5000 pedidos, são necessários cerca de 54 segundos e 450 MB de memória RAM.

O número de restrições e vinculações é sempre 4 e o número de retrocessos é sempre 0. O custo, o tempo de execução, memória utilizada, *prunnings* e *resumptions* aumenta exponencialmente com os dados de entrada (de notar que o gráfico apresentado está em escala logarítmica).

10 Conclusões e Perspetivas de Desenvolvimento

A solução que aqui apresentamos é bastante limitada, sem qualquer correspondência a uma situação real. O enunciado do problema original não é realizável em Prolog com recurso aos módulos de PLR, tanto por questões técnicas como também é limitado à quantidade de informação que é capaz de processar, não conseguindo apresentar resultados em tempo de útil quando são usados dados de entrada semelhantes ao que era de esperar num sistema *cloud*.

Não foram feitas referências a outros autores nem trabalhos porque os problemas que são feitos nesta área não correspondem ao problema que aqui apresentamos.

A Anexos

A.1 Código Fonte

```
1 :- use_module(library(lists)).
     use_module(library(random)).
     use_module(library(clpfd)).
     use_module(library(samsort)).
  config_file('tp2_config.pl').
6
  read_config :-
8
       config_file(F),
9
      open (F, read, Str),
10
       read_file(Str, _),
11
12
      close (Str).
  read_file(Stream, []) :-
14
      at_end_of_stream (Stream).
15
  read_file(Stream, [X|L]) :-
      \+ at_end_of_stream (Stream),
      read (Stream, X),
18
       assert (X),
19
       read_file (Stream, L).
20
21
  all_equal([], _).
  all_equal([X|T], X) :=
      all_equal(T, X).
24
25
  generate_task_types(L, AuthR, ScriptsR, StorageR):-
26
      requests (R),
27
      auth_percentage (AP),
28
      scripts_percentage (SP)
      storage_percentage(StP),
      AuthR is round (R * (AP / 100)),
31
      ScriptsR is round(R * (SP / 100))
      StorageR is round(R * (StP / 100)),
33
      length (AuthL, AuthR),
34
      length(ScriptsL, ScriptsR),
35
      length(StorageL, StorageR),
      all_equal(AuthL, 0),
37
      all_equal(ScriptsL, 1),
38
       all_equal(StorageL, 2),
39
      append ([AuthL, ScriptsL, StorageL], List),
40
      random_permutation(List, L).
41
  highest_request_time (Time) :-
      auth_request_time(Auth), storage_request_time(Storage),
      script_request_time(Script),
      max_member(Time, [Auth, Storage, Script]).
45
```

```
47 % indexed by machine id (0 - \text{auth}, 1 - \text{storage}, 2 - \text{script})
  request\_time(0, X) := auth\_request\_time(X).
  request_time(1, X) :- storage_request_time(X).
  request\_time(2, X) := script\_request\_time(X).
  request_disk(0, X) := auth_request_disk(X).
  request_disk(1, X) :- storage_request_disk(X).
  request_disk(2, X) := script_request_disk(X).
  request_ram(0, X) := auth_request_ram(X).
  request_ram(1, X) := storage_request_ram(X).
  request_ram(2, X) :- script_request_ram(X).
for request_cpu(0, X) :- auth_request_cpu(X).
  request_cpu(1, X) :- storage_request_cpu(X).
  request_cpu(2, X) :- script_request_cpu(X).
  generate_tasks([], [], [], [], []).
  generate_tasks([TaskType|TaskTypes], [TaskDisk|TaskDisks], [
      TaskRAM | TaskRAMs], [TaskCPU | TaskCPUs], [TaskST | TaskSTs], [
      TaskET | TaskETs ] ) :-
      request_time (TaskType, Time),
66
      request_disk(TaskType, Disk),
67
      request_ram (TaskType, RAM),
68
      request_cpu(TaskType, CPU),
69
      TaskDisk \, = \, task \, (\, TaskST \, , \  \, Time \, , \  \, TaskET \, , \  \, Disk \, , \  \, TaskType \, ) \, ,
70
      TaskRAM = task (TaskST, Time, TaskET, RAM, TaskType),
71
      TaskCPU = task(TaskST, Time, TaskET, CPU, TaskType),
72
      generate_tasks(TaskTypes, TaskDisks, TaskRAMs, TaskCPUs,
      TaskSTs, TaskETs).
74
  generate_machines_disk([machine(0, A), machine(1, B), machine
      (2, C)]) :-
      server_auth_disk(A),
76
      server_storage_disk(B),
77
      server_script_disk(C).
78
79
  generate_machines_ram ([machine(0, A), machine(1, B), machine
      (2, C)]) :-
      server_auth_ram(A),
81
      server_storage_ram(B),
82
      server_script_ram(C).
83
  generate_machines_cpu ([machine(0, A), machine(1, B), machine
      (2, C)]) :-
      server_auth_cpu(A),
      server_storage_cpu(B),
87
      server_script_cpu(C).
88
89
```

```
90 calculate_cost_queues(_, [], _, TempSlots, TempSlots).
   calculate_cost_queues ([StartTime|StartTimes], [NextTime]
       NextTimes], OldestTime, TempSlots, TotalSlots):-
       DT is NextTime - StartTime,
92
       calc_time_and_slots(StartTime, OldestTime, DT,
93
       NewOldestTime, TempSlots, NewSlots),
       calculate_cost_queues(StartTimes, NextTimes, NewOldestTime
        NewSlots, TotalSlots).
95
   calc_time_and_slots(StartTime, OldestTime, DT, StartTime,
96
       TempSlots, TempSlots) :-
       routing_spd_time (RouteTime),
97
       highest_request_time (ReqTime),
98
       DT >= RouteTime,
99
       DTOld is StartTime - OldestTime,
100
       DTOld >= ReqTime.
   calc_time_and_slots (StartTime, OldestTime, DT, OldestTime,
103
       TempSlots, TempSlots) :-
       routing_spd_time (RouteTime),
       highest_request_time (RegTime),
       DT >= RouteTime,
106
       DTOld is StartTime - OldestTime,
       DTOld < ReqTime.
109
   calc_time_and_slots (StartTime, OldestTime, DT, OldestTime,
110
       TempSlots, NewSlots) :-
       routing_spd_time (RouteTime),
       highest_request_time (ReqTime),
       DT < RouteTime,
       DTOld is StartTime - OldestTime,
114
       DTOld < ReqTime,
       NewSlots is TempSlots + 1.
   calc_time_and_slots(StartTime, OldestTime, DT, StartTime,
118
       TempSlots, NewSlots) :-
       routing_spd_time (RouteTime),
119
       highest_request_time (ReqTime),
120
       DT < RouteTime,
121
       DTOld is StartTime - OldestTime,
       DTOld >= ReqTime,
123
       NewSlots is TempSlots + 1.
124
   ordered_start_times ([], TempList, List) :-
126
       samsort (TempList, List). W samsort does not remove
       duplicates
   ordered_start_times ([Task|Tasks], TempList, List) :-
       arg(1, Task, ST), %% task(ST, DT, ET, Resc, Mach), arg is
       1-indexed
       append (TempList, [ST], TempList1),
130
```

```
ordered_start_times(Tasks, TempList1, List).
   euro_unicode (8364).
134
   write_profit_or_loss(X) :=
135
       X > 0,
136
       write('+'), write(X).
   write_profit_or_loss(X) :=
138
       write(X).
139
140
   init :-
141
       read_config,
142
       generate_task_types(Types, AuthR, StorageR, ScriptsR),
143
       requests (R),
144
       length (TaskDisks, R), length (TaskRAMs, R), length (TaskCPUs
145
       , R), % needed?
       length (TaskSTs, R), length (TaskETs, R),
146
       generate_tasks(Types, TaskDisks, TaskRAMs, TaskCPUs,
147
       TaskSTs, TaskETs),
       generate_machines_disk (MachineDisks),
       generate_machines_ram (MachineRAMs),
       generate_machines_cpu (MachineCPUs),
       routing_spd_time (RouteTime),
       MaxTaskTime is 1000*60*60*24,
       domain (TaskSTs, RouteTime, MaxTaskTime),
       {\tt domain (TaskETs}\,,\  \, {\tt RouteTime}\,,\  \, {\tt MaxTaskTime})\,\,,
154
       domain ([End],
                         RouteTime, MaxTaskTime),
       maximum (End, TaskETs),
       cumulatives (TaskDisks,
                                MachineDisks,
                                                [bound(upper)]),
                                                [bound(upper)]),
       cumulatives (TaskRAMs,
                                MachineRAMs,
       cumulatives (TaskCPUs,
                                MachineCPUs,
                                                [bound(upper)]),
       append (TaskSTs, [End], Vars),
160
       labeling ([], Vars), W program doesn't run if we use [
       minimize (End)]
       write ('=== FD Statistics ===='), nl,
       fd_statistics, nl,
       ordered_start_times (TaskDisks, [], [StartTime|StartTimes])
164
       calculate_cost_queues([StartTime|StartTimes], StartTimes,
165
       StartTime, 0, Slots),
                      = Statistics ====,'), nl,
       write ('=
       statistics, nl,
167
       spd_slot_price (SlotPrice),
       server_auth_price (AuthPrice),
       server_storage_price (StoragePrice),
       server_script_price (ScriptPrice),
       Cost is AuthPrice + StoragePrice + ScriptPrice + (Slots *
       SlotPrice), %% SPD slots only
       budget (Budget),
       euro_unicode (Euro),
174
```

```
ProfitLoss is Budget - Cost,
       write (' Results "), nl,
176
       write ('Number of Authentication Requests: '), write (AuthR)
177
       , nl,
       write ('Number of Storage Requests: '), write (StorageR), nl
178
       write ('Number of Script Execution Requests: '), write (
       ScriptsR), nl,
       write('Number of SPD slots bought: '), write(Slots), nl,
write('Number of SSD slots bought: '), write(0), nl,
180
181
       write ('Number of Authentication Servers: '), write (1), nl,
182
       write ('Number of Storage Servers: '), write (1), nl,
183
       write ('Number of Script Execution Servers: '), write (1),
184
       write ('Available budget: '), write (Budget), put_code (Euro)
185
       write ('Total cost: '), write (Cost), put_code (Euro), nl,
186
       write('Profit/Loss: '), write_profit_or_loss(ProfitLoss),
187
       put_code(Euro), nl.
                                    tp2.pl
```

A.2 Ficheiro de Configuração

```
1 % base config
_{2} server_auth_disk (120).
3 server_auth_ram(100).
4 server_auth_cpu(200).
5 server_storage_disk(4000).
6 server_storage_ram (85).
7 server_storage_cpu (75).
s server_script_disk(70).
9 server_script_ram (400).
  server_script_cpu (1000).
12 % hardware
spd_slot_price(50).
14 ssd_slot_price(30).
15 server_auth_price(1000).
server_storage_price (1800).
17 server_script_price (2800).
18 disk_unit (250).
19 ram_unit (400).
20 cpu_unit (300).
21 disk_price (100).
22 ram_price (250).
23 cpu_price (420).
24
_{25} % tasks
26 routing_spd_time(100).
```

```
routing_ssd_time (250).
delegation_time(50).
29 auth_request_time (400).
30 storage_request_time (850).
si script_request_time (100).
33 % resources
34 auth_request_disk(50).
35 auth_request_ram(80).
36 auth_request_cpu(75).
37 storage_request_disk(120).
38 storage_request_ram(40).
39 storage_request_cpu(30).
40 script_request_disk(30).
script_request_ram (150).
42 script_request_cpu(220).
43
_{44} % other
45 scripts_to_auth_servers_ratio(2).
46 budget (20000).
47 requests (5000).
48 auth_percentage(25).
49 scripts_percentage (60).
storage_percentage (15).
```

 $tp2_config.pl$